第四～五章：网络层

第四章：网络层——数据平面

1. 网络层概述 (数据平面与控制平面)

- **网络层概述**： 实现分组从发送主机到接收主机的端到端路径选择与转发，即决定分组如何在网络中通过一系列路由器到达目的地。
- **核心功能区分**：
    - **数据平面（转发）**数据平面（转发）：负责本地的路由器操作，即将到达路由器输入链路的分组转移到适当的输出链路。转发时间极短（纳秒级），通常由硬件实现。转发时间极短（纳秒级），通常由硬件实现**硬件**。
    - **控制平面（路由选择）**控制平面（路由选择）：负责确定分组从源到目的地所采取的端到端路径。路由选择时间较长（秒级），通常由软件实现。路由选择时间较长（秒级），通常由软件实现**软件**。
- **两种实现方法**：
    - **传统方法**传统方法：路由选择算法运行在每台路由器内部，路由器之间相互通信来计算转发表。
    - **SDN方法（软件定义网络）**SDN方法（软件定义网络）：控制平面与物理路由器分离，由远程控制器集中计算并分发转发表（流表）给各路由器SDN方法（软件定义网络）：控制平面与物理路由器分离，由远程控制器集中计算并分发转发表（流表）给各路由器。
- **服务模型**服务模型：因特网的网络层提供的是**“尽力而为” (Best-effort)** 的服务。它不保证数据报的交付、不保证按序到达、也不保证带宽和时延。

2. 路由器工作原理 (内部结构)

路由器由四个主要组件构成：输入端口、交换结构（将输入端口连接到输出端口）、输出端口和路由选择处理器（执行路由选择协议）

- 基于目的地转发和泛化转发
- **输入端口**：
    - 核心功能是进行表查找。路由器使用最长前缀匹配规则来查找转发表并确定输出端口

目的地址范围	链路接口
11001000 00010111 00010000 00000000 到 11001000 00010111 00010111 11111111	0
11001000 00010111 00011000 00000000 到 11001000 00010111 00011000 11111111	1
11001000 00010111 00011001 00000000 到 11001000 00010111 00011111 11111111	2
其他	3

显然，对于这个例子，在路由器的转发表中没有必要有 40 亿个表项。例如，我们能够有一个如下仅包括 4 个表项的转发表：

前缀匹配	链路接口
11001000 00010111 00010	0
11001000 00010111 00011000	1
11001000 00010111 00011	2
其他	3

- 硬件查找通常利用TCAM（三态内容可寻址存储器）以保证在常数时间内完成线速查找**TCAM**。

- **交换结构**：将输入端口连接到输出端口，主要有三种方式：

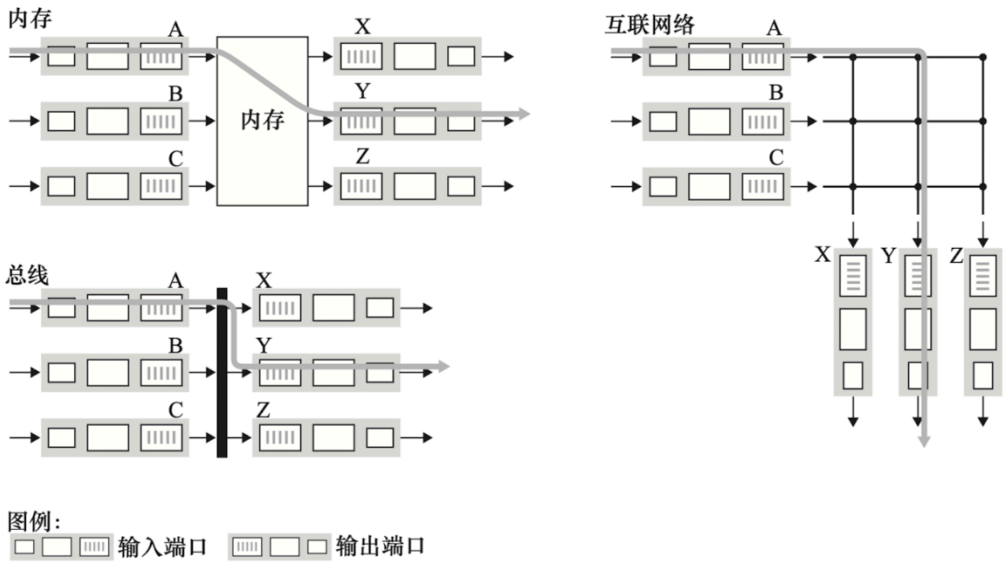


图 4-6　三种交换技术

  - **经内存交换**：受限于内存带宽，一次只能转发一个分组。
  - **经总线交换**：受限于总线速率，一次也只能跨越一个分组。
  - **经互联网络（纵横式）交换**：可以并行转发多个分组，属于非阻塞结构。

- **排队与丢包 (重点考点)**：
  - **输入端口排队**：如果交换结构的速度不够快，输入端口会出现排队。这里会发生HOL阻塞（队首阻塞），即排在队列前面的分组被阻塞，会导致其后的分组即使输出端口空闲也无法通行**HOL阻塞（队首阻塞）**。
  - **输出端口排队**：当交换结构传送分组的速率超过输出链路速率时，分组会在输出端口排队。如果缓存耗尽，就会发生丢包（通常采用弃尾策略或AQM主动队列管理）。

- **缓存膨胀**： 如果端到端路径上的缓存设置过大，会导致持续的排队积压，造成极大的网络时延。

- **分组调度**
  - 包括先进先出（FIFO）

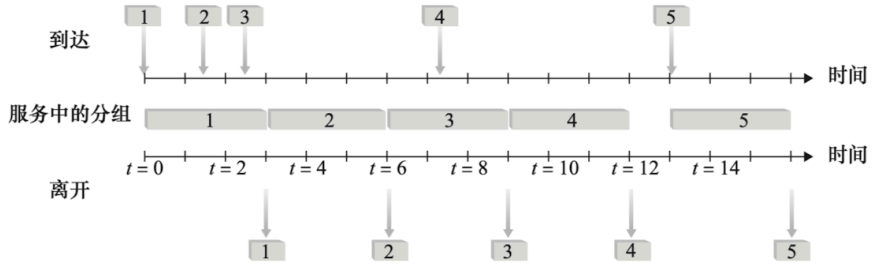


图 4-12　运行中的 FIFO 队列

  - 优先权排队（高优先级先传）

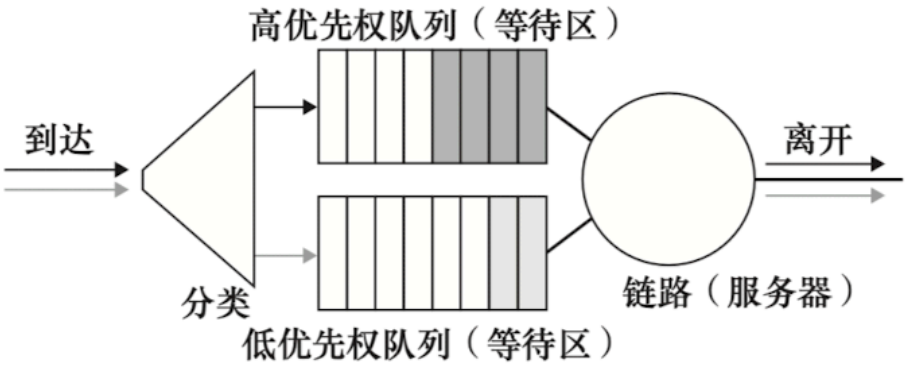


图 4-13　优先权排队模型

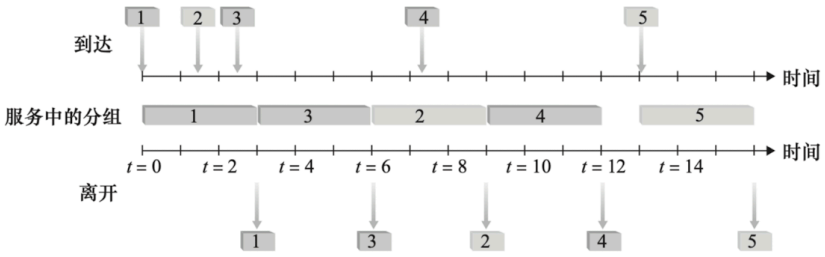


图 4-14　优先权队列的操作

1、3、4处于高优先权队列，一旦分组开始传输就不能打断，比如4在2的传输过程到达，没有打断2，先传完2再传4

  - 循环排队（RR）

类别1传一个，然后类别2传一个，然后再返回类别1.....

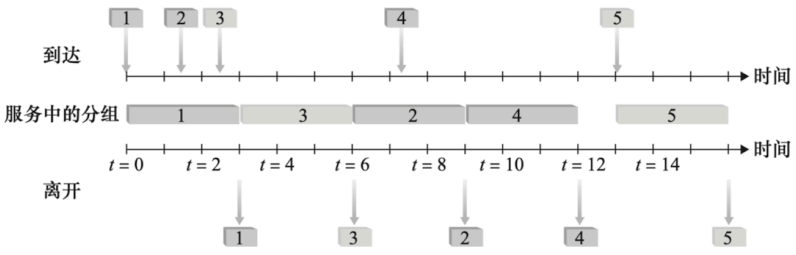


图 4-15　两类循环队列的操作

  - 加权公平排队（WFQ）

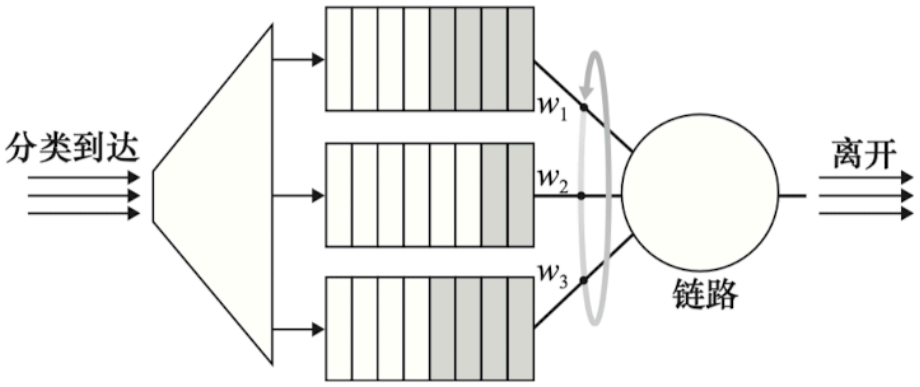


图 4-16　加权公平排队

类i接收到的服务部分等于wi/∑wj

3. IP协议与寻址 (IPv4)

- **IPv4 数据报格式**：

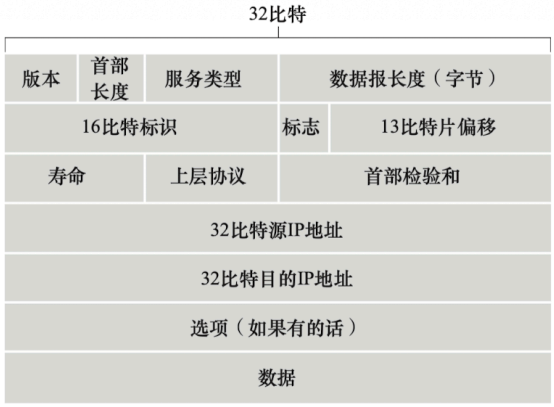


图 4-17　IPv4 数据报格式

  - 首部通常为 20 字节。
  - **协议字段**：这是将网络层与运输层绑定的黏合剂（例如，值为 6 交给 TCP，值为 17 交给 UDP）。
  - **寿命 (TTL)**：每经过一台路由器减 1，减为 0 则丢弃，防止死循环。
  - **标识、标志、片偏移**：用于大分组的分片与重新组装。
  - IP数据包有20字节首部，每个数据报共承载40字节首部（还有20字节TCP首部）
- **IP 编址与 CIDR**：
  - IP地址为 32 比特。每个字节用十进制书写，用点分十进制记法
  - 早期的分类编址（A类、B类、C类网络）灵活性差且浪费地址空间（例如B类网络支持65534台主机，对很多公司而言太大）

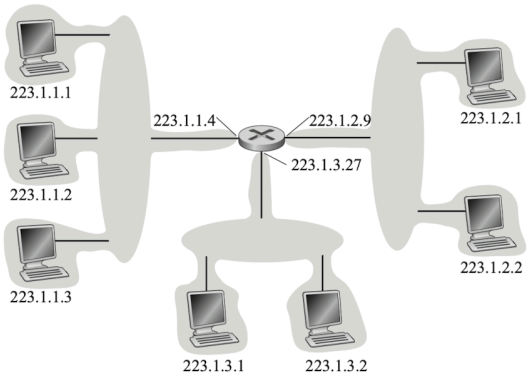


图 4-18　接口地址和子网

用 IP 的术语来说，互联这 3 个主机接口与 1 个路由器接口的网络形成一个**子网**（subnet）［RFC 950］。（在因特网文献中，子网也称为 IP 网络或直接称为网络。）IP 编址为这个子网分配一个地址 223. 1. 1. 0/24，其中的/24（英文读作“slash-24”）记法，有时称为**子网掩码**（network mask），指示 32 比特中的最左侧 24 比特定义了子网地址。因此子网 223. 1. 1. 0/24 由 3 个主机接口（223. 1. 1. 1、223. 1. 1. 2 和 223. 1. 1. 3）和 1 个路由器接口

任何连到223.1.1.0/24的网络主机都有223.1.1.xxx的形式

- 一个地址剩余32-x比特用于区分该组织内部设比，这些设备具有相同网络前缀。IP地址的网络部分被限制为长度9、16、24比特，这种称为分类编制。拥有8、16、24比特子网地址的子网被称为A、B、C类网络
  - A类: 8　　2^(32- 8) -2
  - B类: 16　　2^(32-16) -2
  - C类: 24　　2^(32-24) -2

    C类子网（/24）仅能容纳254台主机
- IP地址由因特网名字和编号分配机构（ICANN）管理
- **CIDR（无类别域间路由选择）：格式为 a.b.c.d/x，其中 x 是网络前缀长度**`a.b.c.d/x``x`**。CIDR 的最大优势是支持路由聚合（地址聚合），大大减少了路由器的转发表表项**路由聚合（地址聚合）**。
- **DHCP (动态主机配置协议)**：
  - 这是一个即插即用（零配置）协议，为主机自动分配 IP、子网掩码、默认网关和 DNS 服务器地址。
  - **核心 4 步骤**核心 4 步骤：DHCP发现（广播目标地址 255.255.255.255）-> DHCP提供（广播） -> DHCP请求(用户从一个或多个服务器提供中选择一个) -> DHCP ACK。

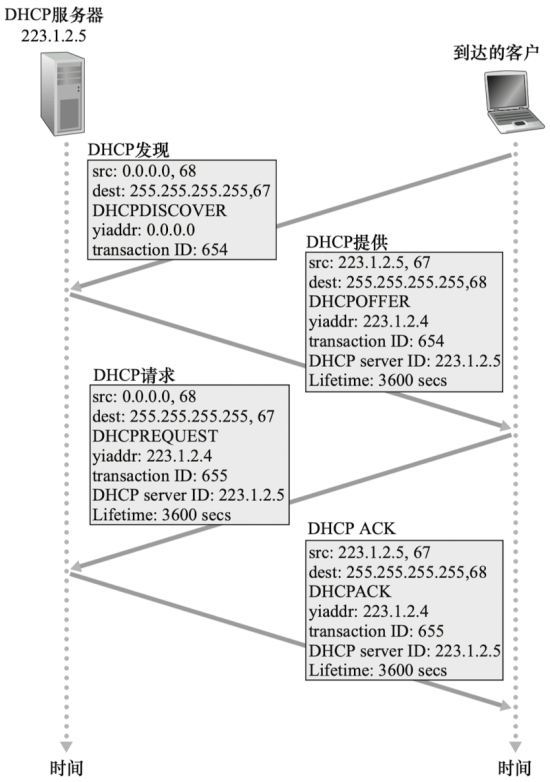


图 4-24　DHCP 客户–服务器交互

- **NAT (网络地址转换)**：
- **解决地址短缺的利器**：使得整个专用网络（如家庭网络 10.0.0.0/24）对外只表现为一个全球唯一的公共 IP 地址`10.0.0.0/24`。
- **工作机制**：路由器维护一张 NAT 转换表，利用 16 比特的端口号，将外部到达分组的目的 IP 和端口映射回内网的私有 IP 和端口。这使得一个公网 IP 可以支持多达 60000 个并发连接
- **ICMP (因特网控制报文协议)**：
- 用于网络层的差错报告和网络探测。
- **Traceroute（路由追踪）的原理**：源主机向目的主机发送一系列 UDP 报文，TTL 分别设为 1, 2, 3...，沿途的路由器在 TTL 耗尽时会返回 ICMP 超时报文，源主机借此探知路径。

4. IPv6 与隧道技术

- **IPv6 的改进**：
  - 地址空间扩大到 128 比特，彻底解决地址耗尽问题**128 比特**。
  - 精简为 40 字节定长首部。
  - **去除了分片功能**去除了分片功能：不允许在中间路由器上进行分片和重组，只能在端系统进行。若分组太大，路由器直接丢弃并返回“分组太大”的 ICMP 差错报文。
  - **去除了首部检验和**去除了首部检验和：加快了路由器的处理速度。
- **从 IPv4 向 IPv6 的迁移机制 —— 建隧道 (Tunneling)**：
  - 思想：当两个 IPv6 节点需要通过中间的 IPv4 网络通信时，将整个 IPv6 数据报封装进 IPv4 数据报的数据字段（有效载荷） 中进行传输。对于中间的 IPv4 路由器而言，它只认为这是个普通的 IPv4 分组

5. 泛化转发和 SDN (OpenFlow)

匹配加操作转发表在openflow中称为流表

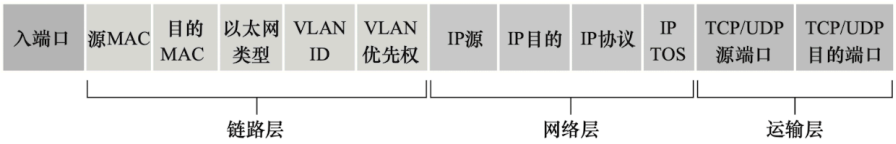


图 4-29　OpenFlow 1. 0 流表的分组匹配字段

- **匹配加操作**：传统的路由器只匹配目的 IP。而泛化转发的流表能够跨越多个协议层（如链路层的 MAC、网络层的 IP、运输层的端口号等十几个字段）进行精确或通配符匹配。
- **操作执行**操作执行：一旦匹配，交换机可以执行包括**转发、丢弃、修改（重写首部字段，如 NAT）**等操作。这使得一台普通的交换机可以通过流表配置，变身为路由器、防火墙或负载均衡器（中间盒）。

第二部分：第四章经典课后题精华精答

R1. 运输层的分组名字是报文段，数据链路层是帧。网络层的分组名字是什么？路由器与链路层交换机间的根本区别是什么？ 答：网络层的分组名字是数据报（Datagram）。根本区别是：路由器是网络层（第3层）设备，基于网络层数据报中的 IP 地址进行转发；链路层交换机是链路层（第2层）设备，基于链路层帧中的 MAC 地址做出转发决定。

R2. 数据平面和控制平面的主要功能分别是什么？ 答：数据平面的主要功能是**转发**（将分组从路由器的输入链路移动到适当的输出链路）；控制平面的主要功能是**路由选择**（决定分组从源到目的地所采取的端到端路径）。

R3. 因特网的网络层服务模型能够保证什么？ 答：因特网的网络层提供的是“尽力而为”的服务，它**什么都不保证**（不保证交付、不保证顺序、不保证带宽、不保证时延上界）。

R6. 路由器的组件中，哪些是用硬件实现的，哪些是用软件实现的？为什么？ 答：输入端口、输出端口和交换结构通常用**硬件**实现，因为它们属于数据平面，要求在纳秒级的时间内完成线速的分组处理和转发。路由选择处理器通常用**软件**实现，因为它属于控制平面，负责执行路由选择协议和网络管理功能，这些操作在毫秒或秒级时间尺度上进行。

R9. 假设一个到达分组匹配了转发表中的两个或多个表项，路由器如何决定输出端口？ 答：使用**最长前缀匹配规则**。路由器会在匹配的表项中选择前缀最长（最具体）的那个表项所对应的输出端口。

R13. 什么是 HOL（队首）阻塞？它出现在输入端口还是输出端口？ 答：HOL 阻塞是指在一个输入队列中排队的分组，因为位于队列首部的分组正等待通过交换结构（例如有输出端口竞争），导致排在其后面的分组即使其目标输出端口空闲也必须等待的现象。它出现在**输入端口**。

R18. 在 IP 首部中，哪个字段能用来确保一个分组的转发不超过 N 台路由器？ 答：寿命（TTL，Time-To-Live）字段。每经过一台路由器，TTL 减 1，为 0 时分组被丢弃。

R27. “路由聚合”意味着什么？为什么它是有用的？ 答：路由聚合（又称地址聚合）是指使用单个网络前缀通告多个子网的能力（借助 CIDR）。这大大减少了路由器中转发表的规模，使得网络路由更高效。

R30. 比较 IPv4 和 IPv6 首部，它们去除了哪些功能以提升效率？ 答：IPv6 去除了 IPv4 中的**分片/重新组装机制**（不允许在中间路由器分片）、去除了**首部检验和**（避免了每过一跳都要重新计算的开销），并将**选项字段**移出了基本首部。

R34. 在 SDN 泛化转发的"匹配加操作"中，举出 3 个能够被匹配的字段和 3 个能被采取的操作。 答：匹配字段例如：源/目的 MAC 地址、源/目的 IP 地址、源/目的 TCP/UDP 端口号。 操作例如：转发到特定输出端口、丢弃该分组、重写/修改首部字段。

第五章：网络层——控制平面

第一部分：核心知识点全面梳理

一、 控制平面概述

控制平面核心作用是控制数据报如何沿着从源主机到目的主机的路径在路由器之间进行转发，并负责网络层组件的配置和管理。

目前存在两种截然不同的控制平面实现方式：

- **传统方法（每路由器控制）**：路由选择算法运行在每台路由器内部。控制平面的路由选择功能与数据平面的转发功能作为统一的整体，全部集成在同一台物理路由器中实现。
- **软件定义网络方法（逻辑集中控制）**：路由器仅负责简单的数据转发，而控制平面的逻辑功能则被转移到一个独立的、远程的控制器服务中实现。

二、 路由选择算法核心机制

路由选择算法旨在寻找从源到目的地的最低成本路径。分为两大阵营：

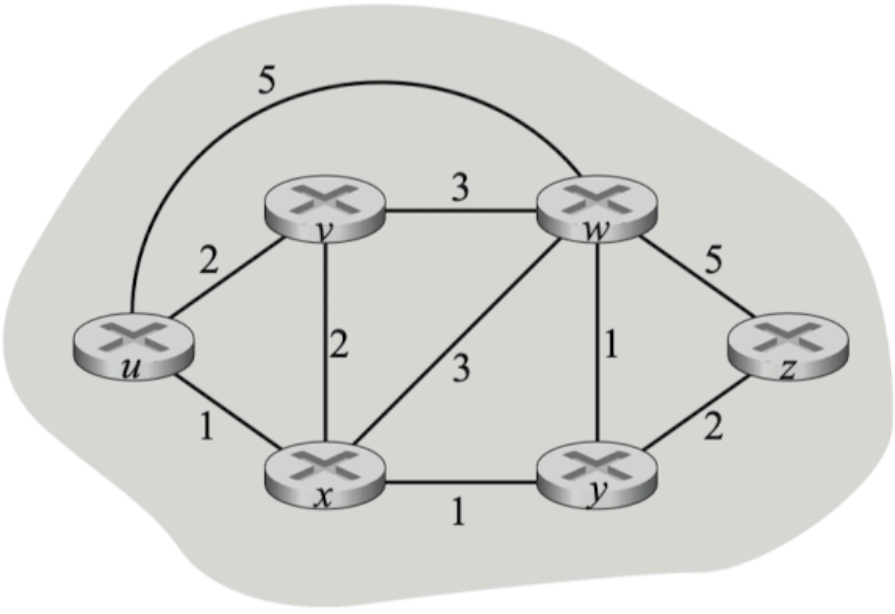


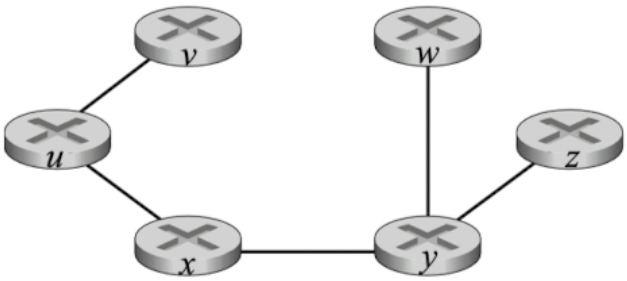
图 5-3　一个计算机网络的抽象图模型

- **全局路由选择算法（LS链路状态算法）**：要求算法必须预先知道网络中每个节点和每条链路的成本信息。最典型的是Dijkstra算法。网络中的每个节点都会向所有其他节点广播自己的链路状态，随后各自在本地运行迪杰斯特拉算法，独立计算出完整的最低成本路径树。

表 5-1　在图 5-3 中的网络上运行的链路状态算法

步骤	N'	$D(v)$，$p(v)$	$D(w)$，$p(w)$	$D(x)$，$p(x)$	$D(y)$，$p(y)$	$D(z)$，$p(z)$
0	u	2，u	5，u	1，u	∞	∞
1	ux	2，u	4，x		2，x	∞
2	uxy	2，u	3，y			4，y
3	$uxyv$		3，y			4，y
4	$uxyvw$					4，y
5	$uxyvwz$					

复杂性为$O(n^2),可能会出现路由振荡。



目的地	链路
v	(u, v)
w	(u, x)
x	(u, x)
y	(u, x)
z	(u, x)

图 5-4　对于节点 u 的最低开销路径和转发表

- **分布式路由选择算法（DV距离矢量算法）**：一种迭代的、异步的、分布式的算法。节点不需要知道全局网络拓扑，它只与自己直接相连的邻居交换路径成本估计值。该算法的一个著名缺陷是“无穷计数”问题，即当某条链路成本急剧增加时，错误的路由信息会在节点之间来回传递，导致成本被不断循环累加。
    - 第n次迭代=最多经过n个中专节点的最短路径
        - 自己行=当前最短
        - 其他行=抄写上次迭代的那一行结果

$$D_x(y) = \min_v \{c(x, v) + D_v(y)\} \quad \text{对 } N \text{ 中的每个节点}$$

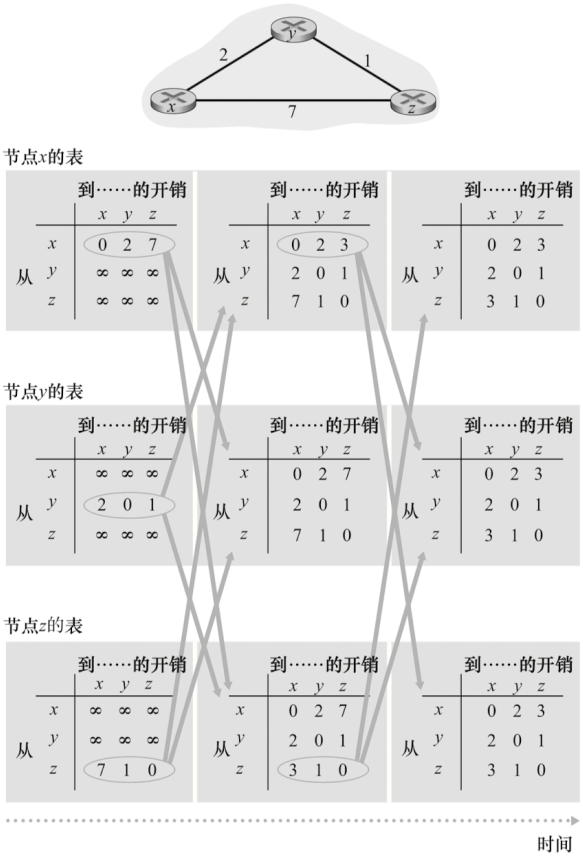


图 5-6　DV 算法

可能会出现无穷计数问题。

三、 因特网中的自治系统内部路由选择

- **自治系统AS：**由于全球路由器数量过于庞大，整个因特网被划分为多个**自治系统**。在自治系统内部运行的路由协议称为内部网关协议。
    - 一个ISP能包括1个或多个AS
    - 一个自治系统由全局唯一的AS号标识
- **RIP：**距离矢量协议，最大支持15跳（DV）
- **开放最短路径优先协议（OSPF）**：这是目前最广泛使用的自治系统内部路由选择协议。它基于链路状态（LS）算法，路由器会向自治系统内的所有其他路由器广播路由选择信息，以构建一致的全局拓扑图并计算最短路径。

四、自治系统间的路由选择（BGP）

1. **边界网关协议（BGP）**：用于连接不同的自治系统。它允许AS向因特网的其他部分通告其存在及其可达的子网前缀。

   BGP转发表：（x，l）：x是前缀（138.16.68/22）,l时路由中的一个接口号

2. **eBGP与iBGP：**

- eBGP（外部BGP）：在不同的自治系统之间传递路由信息。通过eBGP会话，AS能够从相邻AS获取子网可达性信息。
- iBGP（内部BGP）：在自治系统内部的路由器之间传递BGP信息，确保AS内部所有路由器了解外部路由。

两个BGP路由器在TCP连接上交换BGP报文

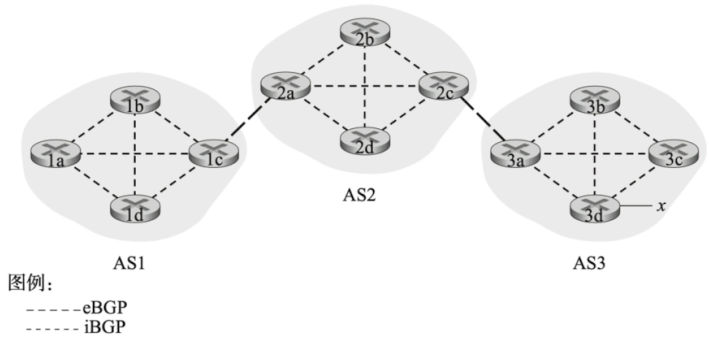


图 5-9　eBGP 和 iBGP 连接

路由=前缀+属性

1. **BGP属性：**

- AS-PATH：记录路由经过的自治系统列表，用于检测环路。当路由器看到包含自己AS号的AS-PATH时，会拒绝该路由。是数据包报文头里面的
- NEXT-HOP：通告路由的下一跳IP地址，指明如何到达该前缀的边界路由器。知识了到吓一跳的特定内部AS路由器

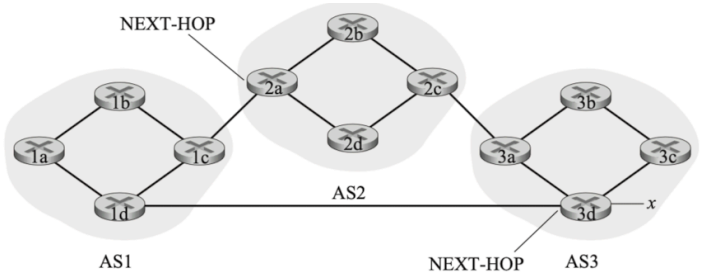


图 5-10　在 AS1 和 AS3 之间增加对等链路后的网络

1. **热土豆路由选择：**BGP路由器在处理多条通往目的地的路径时，倾向于选择距离自己最近的网关，即使这条路径在AS之外的成本很高，这种贪婪策略通过“尽快把包扔出自己的AS”来节省内部资源。
2. **路由器选择算法：**
    - 手动设置一个本地偏好，具有最高本地偏好值的路由被选择
    - 余下的路由中选择具有最短AS-PATH的路由
    - 余下的路由中用热土豆
    - 如果还有余下的，使用BGP标识符来选择路由
3. **前缀与IP任播：**

- 前缀：BGP通告的不仅仅是单个IP地址，而是子网前缀（CIDR块），这实现了地址聚合，减小了转发表大小。
- IP任播：利用BGP实现就近访问。可以：
    - 替换分散在不同位置的不同服务器上的相同内容
    - 让每个用户从最靠近的服务器访问内容
- 路由选择策略：服务商不向其他AS提供路径，不做免费的搬运

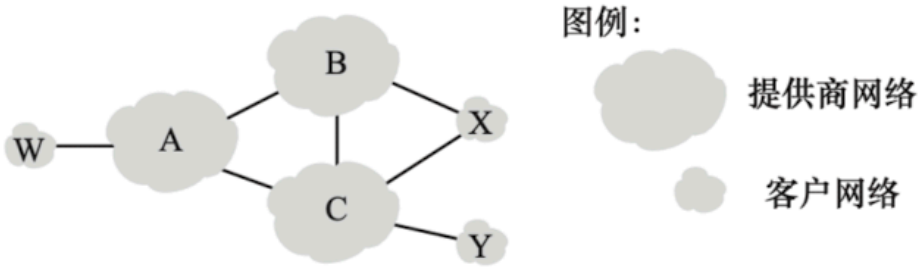


图 5-13　一个简单的 BGP 策略场景

- IP地址分配类型（寻址方式/通信模型）
    - **单播 (Unicast)**：一对一通信。发送方指定唯一的目的 IP 地址，网络将分组精确地送达给那一个特定的主机。
    - **广播 (Broadcast)**：一对所有通信。发送方将分组发往一个特定的广播地址（如255.255.255.255），网络将其复制并发送给子网内的所有主机。
    - **多播 (Multicast)**：一对特定组通信。发送方将分组发往一个多播组地址，只有那些“订阅”或加入了该组的主机才会收到这些分组。
    - **任播 (Anycast)**：一对最近/最佳通信。发送方发往一个任播地址，网络将分组路由到那一组拥有相同任播地址的节点中，在拓扑上距离发送者最近的一个。

五、软件定义网络（SDN）控制平面

1. 核心架构：控制逻辑从物理交换机中剥离，由集中的控制器运行。
2. SDN控制器功能：

- 维护网络状态信息（如主机、链路、交换机状态）。
- 北向接口：与上层的网络控制应用交互。
- 南向接口：使用如OpenFlow等协议向底层交换机安装流表规则。

1. SDN优势：实现了网络的可编程性，能够轻松处理流量工程、负载均衡等复杂逻辑，打破了传统协议僵化的黑盒限制。

六、ICMP与网络管理

- IGMP：使用IP数据报来携带报文，广播时用受控洪泛对已经收到的进行编号加入列表，防止广播风暴，可以形成树。

1. ICMP（互联网控制报文协议）：被主机和路由器用来沟通网络层控制信息。通常被认为是IP一部分。主要用途包括：

- 差错报告：例如目的网络不可达、主机不可达、超时（TTL为0）。
- 网络探测：traceroute程序的实现基础，通过发送TTL递增的分组并捕获返回的ICMP超时报文来逐跳探测路径。

2. 网络管理：

- 简单网络管理协议（SNMP）：用于管理站与代理之间的报文交互，监控设备状态。
- 管理信息库（MIB）：网络设备中被管理的对象的集合，通过ASN.1等格式定义。

- 现代网络管理：引入了NETCONF协议与YANG数据建模语言，支持更复杂的配置自动化和模型驱动管理。

第二部分：课后复习题与简明答案

题目一：基于每路由器控制的控制平面意味着什么？在这种情况下，当我们说网络控制平面和数据平面是“整体地”实现时，是什么意思？
答：基于每路由器控制意味着路由选择算法实实在在地运行在网络中的每一台单独的路由器上。所谓“整体地”实现，是指路由选择逻辑（控制平面）和分组转发动作（数据平面）被紧密绑定并集成在同一台物理硬件设备内部，不可分割。

题目二：基于逻辑上集中控制的控制平面意味着什么？在这种情况下，数据平面和控制平面是在相同的设备或在分离的设备中实现的吗？请解释。
答：意味着计算网络路径和分发转发表的全局逻辑被集中放置在一个专门的远程控制器中。在此架构下，它们是在**分离的设备**中实现的：数据平面的转发功能仍然在本地的物理交换机或路由器中执行，而控制平面的计算和管理功能则转移到了远程的控制器服务器上。

题目三：比较和对照集中式和分布式路由选择算法的性质。
答：集中式路由选择算法（如链路状态算法）需要掌握完整的全局网络拓扑和所有链路的成本信息后，才能集中计算出最低成本路径；而分布式路由选择算法（如距离矢量算法）不需要全局信息，节点最初只知道与其直接相连的链路成本，然后通过与相邻节点不断交换信息，以迭代和分布的方式逐步计算出到达目的地的最低成本路径。

题目四：比较和对照链路状态和距离矢量这两种路由选择算法。
答：链路状态算法通过全网广播让每个节点获取全局拓扑，随后利用迪杰斯特拉算法独立计算路径，收敛速度快且不易产生路由环路；距离矢量算法仅与邻居交换各自的距离向量，依靠贝尔曼福特方程迭代计算，开销较小但收敛速度慢，且容易引发无穷计数问题。

题目五：在距离矢量路由选择中的“无穷计数”是什么意思？
答：无穷计数是指在距离矢量算法中，当某条链路的成本突然大幅增加或链路断开时，由于节点只依赖邻居提供的信息，导致错误的路由信息在相邻节点之间来回相互欺骗、相互更新，使得该路径的成本估计值在循环中无休止地向上累加，直到达到无穷大才发现网络不可达的现象。

题目六：每个自治系统使用相同的自治系统内部路由选择算法是必要的吗？说明其原因。
答：**不必要**。自治系统设立的初衷就是为了实现管理上的独立自治。每个组织或互联网服务提供商都可以根据自己内部网络的规模、性能需求以及管理策略，自由选择最适合的内部路由选择算法（如选择开放最短路径优先协议或路由信息协议等），只要它们在对外与其他自治系统通信时，统一使用标准的边界网关协议即可。